

Thresholding o Umbralización

Alejandra Coy

Nicolas Ingala
Julian Pinelli

Valentina Moretti

8 de Junio del 2026



DEPARTAMENTO
DE COMPUTACION

Facultad de Ciencias Exactas y Naturales - UBA

Motivación

La umbralización de imágenes divide la misma en dos o más regiones basándose en los niveles de intensidad de los píxeles.

Ventajas

- ▶ Simple Implementación
- ▶ Velocidad Computacional

Usos

- ▶ Detección de Objetos
- ▶ Segmentación de Imágenes
- ▶ Extracción de Características



Clasificador Óptimo de Bayes

Óptimo porque tiene la mínima probabilidad de cometer errores al clasificar los píxeles.

Definiciones

- ▶ $P(c_i/x)$: Probabilidad de un píxel x de provenir de la clase c_i .
- ▶ L_{ij} : Pérdida producida cuando se le asigna la clase c_j a un píxel correspondiente a la clase c_i .
- ▶ N_c : Cantidad de clases



Clasificador Óptimo de Bayes

Riesgo o Pérdida Promedio Condicional

$$r_j(x) = \sum_{k=1}^{N_c} L_{kj} * P(c_k/x)$$



Clasificador Óptimo de Bayes

Riesgo o Pérdida Promedio Condicional

$$r_j(x) = \sum_{k=1}^{N_c} L_{kj} * P(c_k/x)$$

► Regla de Bayes: $P(a/b) = P(a) * P(b/a)/P(b)$

$$r_j(x) = \frac{1}{P(x)} \sum_{k=1}^{N_c} L_{kj} * P(x/c_k) * P(c_k)$$



Clasificador Óptimo de Bayes

Riesgo o Pérdida Promedio Condicional

$$r_j(x) = \sum_{k=1}^{N_c} L_{kj} * P(c_k/x)$$

- Regla de Bayes: $P(a/b) = P(a) * P(b/a)/P(b)$

$$r_j(x) = \frac{1}{P(x)} \sum_{k=1}^{N_c} L_{kj} * P(x/c_k) * P(c_k)$$

- Buscamos:

$$\min_{1 \leq j \leq N_c} r_j(x) = \min_{1 \leq j \leq N_c} \sum_{k=1}^{N_c} L_{kj} * P(x/c_k) * P(c_k) \quad (1)$$



Clasificador Óptimo de Bayes

Función de Pérdida

$$L_{ij} = 1 - \delta_{ij} \text{ con } \begin{cases} \delta_{ij} = 1 & \text{si } i = j \\ \delta_{ij} = 0 & \text{si } i \neq j \end{cases}$$



Clasificador Óptimo de Bayes

Función de Decisión

Reemplazando en la ecuación a minimizar:

$$\begin{aligned} \min_{1 \leq j \leq N_c} \sum_{k=1}^{N_c} (1 - \delta_{kj}) * P(x/c_k) * P(c_k) \\ = \min_{1 \leq j \leq N_c} P(x) - P(x/c_j) * P(c_j) \end{aligned}$$



Clasificador Óptimo de Bayes

Función de Decisión

Reemplazando en la ecuación a minimizar:

$$\begin{aligned} \min_{1 \leq j \leq N_c} \sum_{k=1}^{N_c} (1 - \delta_{kj}) * P(x/c_k) * P(c_k) \\ = \min_{1 \leq j \leq N_c} P(x) - P(x/c_j) * P(c_j) \end{aligned}$$

Como $P(x)$ es constante para cualquier j , es equivalente:

$$\max_{1 \leq j \leq N_c} P(x/c_j) * P(c_j) \quad (2)$$

Finalmente le asignamos al pixel x la clase j que maximice esta ecuación



Thresholding

Idea

Tenemos una imagen de objetos claros sobre un fondo oscuro, teniendo dos grupos dominantes de valores de intensidad.

Se elige un umbral T que separa los dos grupos, para transformar la imagen en binaria siguiendo la siguiente asignación para cada punto de la imagen $f(x, y)$:

$$g(x, y) = \begin{cases} 1 & \text{si } f(x, y) > T \\ 0 & \text{si } f(x, y) \leq T \end{cases} \quad (3)$$





¿Cuál es el mejor valor para T ?

Si los objetos y el fondo presentan distribuciones de intensidad bien separadas, es posible utilizar un único umbral para toda la imagen (**Global Thresholding**).

Sin embargo, el valor óptimo del umbral suele variar de una imagen a otra, por lo que resulta útil contar con algoritmos que lo estimen automáticamente.

Ejemplo



Global Basic Thresholding

Umbralización Global Basica (Iterativa)

El algoritmo busca un umbral que quede aproximadamente en el medio de las intensidades medias de ambos grupos.

Algoritmo

1. Elegir una estimación inicial del umbral T .



Global Basic Thresholding

Umbralización Global Basica (Iterativa)

El algoritmo busca un umbral que quede aproximadamente en el medio de las intensidades medias de ambos grupos.

Algoritmo

1. Elegir una estimación inicial del umbral T .
2. Dividir los píxeles en dos grupos:
 - ▶ G_1 : píxeles con intensidad mayor que T .
 - ▶ G_2 : píxeles con intensidad menor o igual que T .



Global Basic Thresholding

Algoritmo

3. Calcular las medias de intensidad de cada grupo:

- ▶ Media de G_1 : $m_1 = \frac{\sum_{i=T+1}^{L-1} i * \frac{h(i)}{N}}{\sum_{i=T+1}^{L-1} \frac{h(i)}{N}}$
- ▶ Media de G_2 : $m_2 = \frac{\sum_{i=0}^T i * \frac{h(i)}{N}}{\sum_{i=0}^T \frac{h(i)}{N}}$

Donde:

- L es la cantidad de valores de intensidad posibles
- i es la intensidad del pixel.
- $h(i)$ es la cantidad de pixeles con intensidad i .
- N es la cantidad total de pixeles de la imagen



Global Basic Thresholding

Algoritmo

4. Actualizar el umbral:

$$T_{\text{nuevo}} = \frac{m_1 + m_2}{2}$$



Global Basic Thresholding

Algoritmo

4. Actualizar el umbral:

$$T_{\text{nuevo}} = \frac{m_1 + m_2}{2}$$

5. Repetir los pasos 2 a 4 hasta que el cambio entre dos iteraciones consecutivas sea menor que una tolerancia ΔT .



Global Basic Thresholding

Resumen Algoritmo

1. Elegir una estimación inicial del umbral T .
2. Dividir los píxeles en dos grupos (G_1 y G_2) según T .
3. Calcular las medias de intensidad de cada grupo (m_1 y m_2).
4. Actualizar el umbral tomando el valor medio entre las medias de los grupos.
5. Repetir los pasos 2 a 4 hasta que el cambio sea menor que una tolerancia ΔT .



Método de Umbralización de Otsu

Umbralización Global Óptima

El algoritmo busca el umbral que maximiza la "distancia" entre ambos grupos.

Idea principal

- ▶ Se consideran dos clases de píxeles:
 - Fondo (c_1)
 - Objeto (c_2)
- ▶ Un buen umbral debe generar clases con niveles de intensidad bien diferenciados.



Método de Otsu

Selecciona automáticamente el umbral que maximiza la separación entre clases.

Para explicar su funcionamiento, primero necesitamos introducir algunos conceptos de probabilidad.



Método de Otsu

Dada una imagen de tamaño $M \times N$, con $L = 256$ valores de intensidad posibles.

Sea n_i la cantidad de píxeles con intensidad i . Luego, el histograma normalizado tiene componentes $p_i = \frac{n_i}{MN}$ de modo que:

$$\sum_{i=0}^{L-1} p_i = 1$$



Método de Otsu

Para un umbral k , separamos las clases:

$$c_1 = \{x \mid i_x \in [0, k]\}$$

$$c_2 = \{x \mid i_x \in k + 1, L - 1\}$$



Método de Otsu

Para un umbral k , separamos las clases:

$$c_1 = \{(x, y) \mid i_{xy} \in [0, k]\}$$

$$c_2 = \{(x, y) \mid i_{xy} \in k + 1, L - 1]\}$$

Las probabilidades de cada clase vienen dadas por:

$$P_1(k) = \sum_{i=0}^k p_i$$

$$P_2(k) = \sum_{i=k+1}^{L-1} p_i = 1 - P_1(k)$$



Método de Otsu

Intensidades Medias de las Clases

- Intensidad media de los píxeles pertenecientes a c_1 :

$$m_1(k) = \sum_{i=0}^k i P(i/c_1) = \sum_{i=0}^k i P(c_1/i) P(i) / P(c_1)$$

$$m_1(k) = \frac{1}{P_1(k)} \sum_{i=0}^k i p_i$$



Método de Otsu

Intensidades Medias de las Clases

- Intensidad media de los píxeles pertenecientes a c_1 :

$$m_1(k) = \frac{1}{P_1(k)} \sum_{i=0}^k i p_i$$

- Intensidad media de los píxeles pertenecientes a c_2 :

$$m_2(k) = \frac{1}{P_2(k)} \sum_{i=k+1}^{L-1} i p_i$$



Método de Otsu

Otras Medias

- Intensidad media acumulada hasta un nivel k:

$$m(k) = \sum_{i=0}^k i p_i$$

- Intensidad media global:

$$m_G = \sum_{i=0}^{L-1} i p_i$$



Método de Otsu

Varianza Entre Clases

La separación entre clases se mide mediante:

$$\sigma_B^2(k) = P_1(k)P_2(k) [m_1(k) - m_2(k)]^2$$

Forma equivalente utilizada en la implementación:

$$\sigma_B^2(k) = \frac{[m_G P_1(k) - m(k)]^2}{P_1(k) [1 - P_1(k)]}$$

Cuanto mayor sea $\sigma_B^2(k)$, mejor separadas estarán las clases.



Método de Otsu

Obtención del Umbral Óptimo

Se evalúa la varianza entre clases para todos los posibles umbrales:

$$k = 0, 1, \dots, L - 1$$

El umbral óptimo es:

$$k^* = \arg \max_{0 \leq k \leq L-1} \sigma_B^2(k)$$

Finalmente asignamos los pixeles:

$$g(x, y) = \begin{cases} 1 & \text{si } f(x, y) > k^* \\ 0 & \text{si } f(x, y) \leq k^* \end{cases}$$



Método de Otsu

Resumen Algoritmo del Método de Otsu

1. Calcular en histograma normalizado de la intensidad de los pixeles de la imagen, obteniendo cada componente p_i , $i = 0, 1, 2, \dots, L - 1$.
2. Calcular $P_1(k)$, para cada k , para $k = 0, 1, 2, \dots, L - 1$.
3. Calcular $m(k)$ para cada k , para $k = 0, 1, 2, \dots, L - 1$.
4. Calcular m_G .
5. Calcular $\sigma_B^2(k)$, para cada k , para $k = 0, 1, 2, \dots, L - 1$.
6. Obtener k^* buscando el k máximo de entre los valores obtenidos. Si se encuentra mas de un k máximo calcular k^* como su promedio.
7. Asignar a los pixeles sus respectivos valores según k^*



Umbralización Variable

Variable Thresholding

Se utiliza el término **Umbralización Variable** cuando el valor para el umbral T cambia a lo largo de la imagen.

Tipos de Umbralización Variable

- ▶ *Umbralización Local o Regional*: El valor de T depende del vecindario del pixel (x, y) .
- ▶ *Umbralización Dinámica o Adaptativa*: El valor de T depende solamente de las coordenadas del pixel (x, y) .



Umbralización Local

El umbral T que se utiliza para cada pixel (x, y) depende de una o más características de su vecindario.

Un caso podría ser, por ejemplo, tomar la media y la desviación estándar de los vecinos de un pixel para determinar su umbral. Estas medidas permiten describir la intensidad promedio y el contraste del vecindario.

Notación

- ▶ m_{xy} : media del vecindario del pixel (x, y)
- ▶ σ_{xy} : desviación estándar del vecindario del pixel (x, y)
- ▶ S_{xy} : vecindario centrado en el pixel (x, y)



Umbralización Local

Umbralos frecuentemente utilizados

- ▶ $T_{xy} = a \sigma_{xy} + b m_{xy}$
- ▶ $T_{xy} = a \sigma_{xy} + b m_G$

Donde a y b son constantes no negativas que se determinan experimentalmente

El uso de m_G da mejores resultado cuando el fondo es practicamente constante y la intensidad de los pixeles de los objetos son notoriamente superiores o inferiores al fondo.



Umbralización Local

Función de Decisión

$$g(x, y) = \begin{cases} 1 & \text{si } f(x, y) > T_{xy} \\ 0 & \text{si } f(x, y) \leq T_{xy} \end{cases}$$

También se pueden utilizar predicados:

$$g(x, y) = \begin{cases} 1 & \text{si } Q(\text{parámetros locales}) \text{ es TRUE} \\ 0 & \text{si } Q(\text{parámetros locales}) \text{ es FALSE} \end{cases}$$

Ejemplo de Predicado

$$Q(\sigma_{xy}, m_{xy}) = \begin{cases} TRUE & \text{si } f(x, y) > a \sigma_{xy} \text{ Y } f(x, y) > b m_{xy} \\ FALSE & \text{sino} \end{cases}$$



¡GRACIAS!

¿Preguntas?



**DEPARTAMENTO
DE COMPUTACION**

Facultad de Ciencias Exactas y Naturales - UBA