

# Histogram of Oriented Gradients (HoG)

Elementos de Reconocimiento Visual

HogRiders Group

Martín Sinnona   Horacio Gomez   Franco Perotti  
Franco Vanotti   Ignacio Rodriguez

Departamento de Computación  
Facultad de Ciencias Exactas y Naturales  
Universidad de Buenos Aires

17/06/2026



# ¿Qué vamos a ver?

- 1 Motivación
- 2 Datasets
- 3 Repaso Gradientes
- 4 Método HOG
  - Celdas
  - Bloques y Normalización
  - Descriptor HOG
  - Clasificación
  - Resumen
- 5 Parámetros
  - Color y Contexto
  - Gradiente
  - Ángulos
  - Tamaño de Celdas y Bloques
  - Esquemas de Normalización
- 6 Discusión

# 1.1 Motivación: Desafíos y Objetivo

## Detección de Personas

El paper se propone lograr reconocimiento de personas en imágenes.

# 1.1 Motivación: Desafíos y Objetivo

## Detección de Personas

El paper se propone lograr reconocimiento de personas en imágenes.

## Dificultades: ¿Por qué es una tarea compleja?

- **Variabilidad:** Cambios constantes en la pose de las personas, el tamaño, la perspectiva y la vestimenta.
- **Escenarios ruidosos:** Fondos caóticos, oclusiones parciales y condiciones de iluminación difíciles.

# 1.1 Motivación: Desafíos y Objetivo

## Detección de Personas

El paper se propone lograr reconocimiento de personas en imágenes.

## Dificultades: ¿Por qué es una tarea compleja?

- **Variabilidad:** Cambios constantes en la pose de las personas, el tamaño, la perspectiva y la vestimenta.
- **Escenarios ruidosos:** Fondos caóticos, oclusiones parciales y condiciones de iluminación difíciles.

## Objetivo:

Lograr un **descriptor** de características lo suficientemente robusto para permitir la detección confiable de formas en contextos del mundo real (vigilancia, asistencia a la conducción, análisis de imágenes).

## 1.2 Motivación: La Intuición de HOG

### La Gran Idea

La apariencia y la forma local de un objeto pueden caracterizarse mediante la **distribución de los gradientes** locales.

## 1.2 Motivación: La Intuición de HOG

### La Gran Idea

La apariencia y la forma local de un objeto pueden caracterizarse mediante la **distribución de los gradientes** locales.

- **Invariancia:** Al basarse en histogramas locales, el método tolera pequeñas traslaciones y rotaciones sin perder la capacidad de reconocimiento.
- **Más allá de los humanos:** El descriptor no está atado a la anatomía humana; captura la esencia de cualquier silueta geométrica (Aunque no nos servirá el mismo clasificador).

## 1.3 Motivación: Ejemplo de celda

### Vámos con un ejemplo

Acá vamos a ver cómo transformamos una **celda de la imagen**: en lugar de quedarnos con todos los gradientes individuales de cada píxel, los resumimos en un **histograma de orientaciones**.

De esta forma, perdemos la información exacta de dónde estaba cada gradiente dentro de la celda, pero conservamos qué **direcciones predominan**.






## 1.3 Motivación: Ejemplo de celda




### Vámos con un ejemplo

Acá vamos a ver cómo transformamos una **celda de la imagen**: en lugar de quedarnos con todos los gradientes individuales de cada píxel, los resumimos en un **histograma de orientaciones**.

De esta forma, perdemos la información exacta de dónde estaba cada gradiente dentro de la celda, pero conservamos qué **direcciones predominan**.



# 1.4 Motivación: Originales vs. HOG



## 2. Datasets

- **MIT Pedestrian Dataset:** 709 imágenes de peatones de frente y detrás, limitadas en las poses. Relativamente simple y sin mucha variabilidad.




## 2. Datasets

- **INRIA Person Dataset:** 1805 imágenes más variadas y realistas, con cambios de escala, postura, iluminación y fondos complejos.



### 3. Repaso Gradientes: Intuición Visual



Dos tipos de gradientes: las flechas azules indican dirección; las zonas claras representan valores de píxel más altos.




Imagen original y gradientes en  $x$  ( $g_x$ ) e  $y$  ( $g_y$ ): gris indica cambio pequeño; blanco/negro, cambio grande.

### 3. Repaso Gradientes: Magnitud y Orientación

A partir de las derivadas horizontales y verticales,  $g_x$  y  $g_y$ , se calcula:

#### Magnitud del Gradiente (con $L_2$ )

$$|g| = \sqrt{g_x^2 + g_y^2}$$

#### Orientación del gradiente

$$\theta = \arctan\left(\frac{g_y}{g_x}\right)$$

- $|g|$  mide qué tan fuerte es el cambio de intensidad.
- $\theta$  indica la dirección en la que ocurre ese cambio.

### 3. Repaso Gradientes: Magnitud y Orientación Visualizadas

Grayscale






Imagen en escala de grises

Gradient Magnitude



Magnitud del gradiente

Gradient Orientation [0, 180]



Orientación del gradiente  
codificados por color

## 4. Método HOG

¿Qué es HOG?

Abreviatura de **histogramas de gradientes**. Nuestro descriptor HOG estará compuesto de muchos histogramas.



## 4. Método HOG

### ¿Qué es HOG?

Abreviatura de **histogramas de gradientes**. Nuestro descriptor HOG estará compuesto de muchos histogramas.

### Idea General del Método

Partimos la imagen en celdas, a cada celda calculamos un histograma de gradientes, hacemos un par de cositas más, y armamos el descriptor HOG para que un Clasificador Supervisado decida si la imagen contiene una persona.

## 4.1 Construcción de Histogramas Locales

### De píxeles a gradientes

Calculamos las derivadas horizontales y verticales de cada píxel para obtener la información local del cambio de intensidad.

## 4.1 Construcción de Histogramas Locales

### De píxeles a gradientes

Calculamos las derivadas horizontales y verticales de cada píxel para obtener la información local del cambio de intensidad.

### De gradientes a celdas

Dividimos la imagen geoméricamente en pequeñas regiones discretas llamadas **celdas de  $8 \times 8$  píxeles**.

## 4.1 Construcción de Histogramas Locales

### De píxeles a gradientes

Calculamos las derivadas horizontales y verticales de cada píxel para obtener la información local del cambio de intensidad.


### De gradientes a celdas

Dividimos la imagen geoméricamente en pequeñas regiones discretas llamadas **celdas de  $8 \times 8$  píxeles**.

### De celdas a histogramas

Cada píxel dentro de la celda aporta un voto ponderado por su magnitud a un histograma local de **9 bins** distribuidos entre  $0^\circ$  y  $180^\circ$ .

## 4.1 Celdas: Ejemplo



|     |     |     |     |     |     |     |     |
|-----|-----|-----|-----|-----|-----|-----|-----|
| 2   | 3   | 4   | 4   | 3   | 4   | 2   | 2   |
| 5   | 11  | 17  | 13  | 7   | 9   | 3   | 4   |
| 11  | 21  | 23  | 27  | 22  | 17  | 4   | 6   |
| 23  | 99  | 165 | 135 | 85  | 32  | 26  | 2   |
| 91  | 155 | 133 | 136 | 144 | 152 | 57  | 28  |
| 98  | 196 | 76  | 38  | 26  | 60  | 170 | 51  |
| 165 | 60  | 60  | 27  | 77  | 85  | 43  | 136 |
| 71  | 13  | 34  | 23  | 108 | 27  | 48  | 110 |


**Gradient Magnitude**

|     |     |     |     |     |     |     |     |
|-----|-----|-----|-----|-----|-----|-----|-----|
| 80  | 36  | 5   | 10  | 0   | 64  | 90  | 73  |
| 37  | 9   | 9   | 179 | 78  | 27  | 169 | 166 |
| 87  | 136 | 173 | 39  | 102 | 163 | 152 | 176 |
| 76  | 13  | 1   | 168 | 159 | 22  | 125 | 143 |
| 120 | 70  | 14  | 150 | 145 | 144 | 145 | 143 |
| 58  | 86  | 119 | 98  | 100 | 101 | 133 | 113 |
| 30  | 65  | 157 | 75  | 78  | 165 | 145 | 124 |
| 11  | 170 | 91  | 4   | 110 | 17  | 133 | 110 |

**Gradient Direction**

La imagen se divide en celdas de  $8 \times 8$  píxeles. Para un parche se observan, a la derecha, las matrices de magnitud y orientación del gradiente.

## 4.1 Celdas: Ejemplo




Cada píxel vota en el histograma de orientaciones con peso dado por su magnitud. Si la dirección cae entre dos bins, por ejemplo  $10^\circ$ , el voto se reparte entre las casillas contiguas.

## 4.2 Bloques y Normalización

### ¿Por qué?

Los gradientes cambian con iluminación y contraste; por eso se normalizan localmente.

- Las celdas se agrupan en **bloques** espaciales y cada bloque se normaliza por contraste.
- Los bloques se solapan: una misma celda aparece varias veces, normalizada respecto de distintos vecindarios.
- Esa redundancia mejora el rendimiento, porque hace al descriptor más robusto a cambios locales de iluminación y fondo.
- En la configuración estándar: bloques de  $16 \times 16$  píxeles, formados por  $2 \times 2$  celdas.



## 4.3 El Descriptor HOG Final

### De bloques al descriptor

HOG concatena secuencialmente los histogramas normalizados de todos los bloques. Se obtiene un vector que captura la forma general de la imagen.



## 4.3 El Descriptor HOG Final


### De bloques al descriptor

HOG concatena secuencialmente los histogramas normalizados de todos los bloques. Se obtiene un vector que captura la forma general de la imagen.

Input image



Histogram of Oriented Gradients



## 4.4 Clasificación: Concepto de SVMs

El paper emplea un clasificador SVM para definir si hay o no una persona en la imagen.

### ¿Qué es yCuál es el objetivo del SVM?

Algoritmo de Aprendizaje Supervizado que busca el hiperplano que **maximice el margen** entre las muestras más conflictivas de ambos grupos, conocidas como *Vectores de Soporte*.

## 4.4 Clasificación: Concepto de SVMs


El paper emplea un clasificador SVM para definir si hay o no una persona en la imagen.

### ¿Qué es yCuál es el objetivo del SVM?

Algoritmo de Aprendizaje Supervizado que busca el hiperplano que **maximice el margen** entre las muestras más conflictivas de ambos grupos, conocidas como *Vectores de Soporte*.

### SVM Lineal

- Separa los datos usando una **línea o plano recto**.
- **Ventaja:** Computacionalmente **muv rápido**.



## 4.4 Clasificación: Concepto de SVMs


El paper emplea un clasificador SVM para definir si hay o no una persona en la imagen.

### ¿Qué es yCuál es el objetivo del SVM?

Algoritmo de Aprendizaje Supervizado que busca el hiperplano que **maximice el margen** entre las muestras más conflictivas de ambos grupos, conocidas como *Vectores de Soporte*.


#### SVM Lineal

- Separa los datos usando una **línea o plano recto**.
- **Ventaia:** Computacionalmente **muv rápido**.



#### SVM Gaussiano (Kernel RBF)

- Genera fronteras de decisión **curvas o complejas**.
- **Desventaja:** Demasiado costoso.



## 4.4 Clasificación: Persona vs. No persona

### Persona vs. No persona

El descriptor HOG de cada ventana se entrega a un clasificador supervisado para determinar la presencia de una persona.

## 4.4 Clasificación: Persona vs. No persona

### Persona vs. No persona

El descriptor HOG de cada ventana se entrega a un clasificador supervisado para determinar la presencia de una persona.

- El paper usa por defecto un **SVM lineal** como clasificador base.
- La salida del SVM es un score: valores altos indican mayor evidencia de una persona.
- La ventana de detección se escanea sobre distintas posiciones y escalas de la imagen.
- Luego se combinan respuestas cercanas usando supresión de no-máximos.
- Un SVM con kernel gaussiano mejora algo el rendimiento, pero aumenta mucho el costo computacional.

## 4.5 Resumen

- ④ **Gradientes:** Se calculan magnitud y orientación de los cambios locales de intensidad.

## 4.5 Resumen

- ① **Gradientes:** Se calculan magnitud y orientación de los cambios locales de intensidad.
- ② **Celdas:** Cada región acumula un histograma de orientaciones de gradiente.



## 4.5 Resumen

- ➊ **Gradientes:** Se calculan magnitud y orientación de los cambios locales de intensidad.
- ➋ **Celdas:** Cada región acumula un histograma de orientaciones de gradiente.
- ➌ **Normalización por Bloques:** Se normalizan grupos de celdas solapados para mejorar robustez.

## 4.5 Resumen

- ➊ **Gradientes:** Se calculan magnitud y orientación de los cambios locales de intensidad.
- ➋ **Celdas:** Cada región acumula un histograma de orientaciones de gradiente.
- ➌ **Normalización por Bloques:** Se normalizan grupos de celdas solapados para mejorar robustez.
- ➍ **Descriptor HOG:** Se concatenan los histogramas normalizados de la ventana de detección.

## 4.5 Resumen

- ➊ **Gradientes:** Se calculan magnitud y orientación de los cambios locales de intensidad.
- ➋ **Celdas:** Cada región acumula un histograma de orientaciones de gradiente.
- ➌ **Normalización por Bloques:** Se normalizan grupos de celdas solapados para mejorar robustez.
- ➍ **Descriptor HOG:** Se concatenan los histogramas normalizados de la ventana de detección.
- ➎ **Clasificación:** Un SVM lineal toma los descriptores concatenados y devuelve el score de detección de un humano.

## 4.5 Resumen

- ➊ **Gradientes:** Se calculan magnitud y orientación de los cambios locales de intensidad.
- ➋ **Celdas:** Cada región acumula un histograma de orientaciones de gradiente.
- ➌ **Normalización por Bloques:** Se normalizan grupos de celdas solapados para mejorar robustez.
- ➍ **Descriptor HOG:** Se concatenan los histogramas normalizados de la ventana de detección.
- ➎ **Clasificación:** Un SVM lineal toma los descriptores concatenados y devuelve el score de detección de un humano.

## 4.5 Resumen

- ➊ **Gradientes:** Se calculan magnitud y orientación de los cambios locales de intensidad.
- ➋ **Celdas:** Cada región acumula un histograma de orientaciones de gradiente.
- ➌ **Normalización por Bloques:** Se normalizan grupos de celdas solapados para mejorar robustez.
- ➍ **Descriptor HOG:** Se concatenan los histogramas normalizados de la ventana de detección.
- ➎ **Clasificación:** Un SVM lineal toma los descriptores concatenados y devuelve el score de detección de un humano.

**¿Y si cambiamos los parámetros?**

## 5.1 Parámetros: Color y Contexto

### Preprocesamiento

En el paper se plantea realizar una normalización gamma. Sin embargo, la mejora es marginal.

## 5.1 Parámetros: Color y Contexto

### Preprocesamiento

En el paper se plantea realizar una normalización gamma. Sin embargo, la mejora es marginal.

- **Correcciones:** Aplicar compresión de raíz cuadrada ayuda ligeramente, pero aplicar logaritmos es un ajuste demasiado fuerte y empeora la detección.
- **Espacio de color:** Procesar los canales RGB o LAB rinde mejor que limitar la imagen únicamente a escala de grises.



## 5.2 Parámetros: Gradiente

- **Cálculo óptimo:** Las derivadas 1D simples  $[-1, 0, 1]$  centradas sin suavizado funcionan mejor.

## 5.2 Parámetros: Gradiente

- **Cálculo óptimo:** Las derivadas 1D simples  $[-1, 0, 1]$  centradas sin suavizado funcionan mejor.
- **El problema del suavizado:** Aplicar suavizado Gaussiano antes de derivar empeora drásticamente la tasa de detección.
- **Máscaras complejas:** Usar filtros más grandes como Sobel de  $3 \times 3$  o máscaras diagonales también disminuye el rendimiento.

## 5.2 Parámetros: Gradiente

- **Cálculo óptimo:** Las derivadas 1D simples  $[-1, 0, 1]$  centradas sin suavizado funcionan mejor.
- **El problema del suavizado:** Aplicar suavizado Gaussiano antes de derivar empeora drásticamente la tasa de detección.
- **Máscaras complejas:** Usar filtros más grandes como Sobel de  $3 \times 3$  o máscaras diagonales también disminuye el rendimiento.
- **¿Por qué?:** Gran parte de la información útil proviene de bordes abruptos a escalas finas; difuminarlos es contraproducente.

## 5.3 Parámetros: Ángulos

- **Cantidad de Bins:** El desempeño mejora al aumentar los bins de orientación, pero se estanca alrededor de los 9 bins.
- **Rango (¿Con o sin signo?):** En el caso de siluetas de personas, funciona mejor usar el rango de  $0^\circ$  a  $180^\circ$ , ignorando el signo del gradiente. Usar gradientes con signo ( $0^\circ$  a  $360^\circ$ ) empeora los resultados debido a la gran variabilidad de colores de ropa y fondos. Para objetos con mismas características se espera un resultado similar.

## 5.4 Parámetros: El Tamaño de Celdas y Bloques

- **Tamaño de las celdas:** Las celdas de entre 6 y 8 píxeles de ancho rinden mejor. Coincide de forma interesante con el ancho promedio de las extremidades humanas en las fotos.
- **Tamaño de los bloques:** Los bloques de  $2 \times 2$  o  $3 \times 3$  celdas funcionan mejor. Si el bloque es gigante, el descriptor no se adapta bien a los cambios locales; si es diminuto, se pierde información clave.
- **La combinación ganadora:** La menor tasa de error (10.4 %) se consiguió configurando bloques de  $3 \times 3$  celdas donde cada celda mide  $6 \times 6$  píxeles. Esta combinación fue para imágenes de  $64 \times 128$  píxeles.
- **La importancia del contexto:** El tamaño de la imagen incluye intencionalmente un margen alrededor de la silueta. Reducir este borde para ajustar más la forma quita contexto valioso y empeora la detección.

## 5.5 Parámetros: Esquemas de Normalización

- **Paso crítico:** Omitir por completo la normalización dispara la tasa de error en un 27 %.
- **Esquemas evaluados:** Las métricas L2-Hys, L2-norm y L1-sqrt funcionan igual de bien en la práctica. Por el contrario, la normalización simple L1-norm empeora el rendimiento.
- **Solapamiento (Overlap):** Evaluar una misma celda múltiples veces bajo distintos contextos locales (los bloques superpuestos) mejora el resultado final.

## 6. Discusión

### Puntos de Discusión:

- **Manejo de Escalas y Tamaños:** Como el algoritmo usa una ventana de tamaño fijo ( $64 \times 128$ ), la solución para detectar una o más personas con distintos tamaños es escanear la imagen por secciones y luego reescalarla y repetir el escaneo.
- **Modelos Basados en Partes:** El cuerpo humano es altamente articulado y adopta posturas complejas. La evolución lógica es usar clasificadores que **detecten las partes del cuerpo de forma independiente** y analicen sus relaciones espaciales para inferir si conforman a una persona.
- **Formas No Humanas** Es posible adaptar los descriptores HoG para cualquier forma, y se deberá usar un clasificador especializado.

## 6. Discusión

### Puntos de Discusión:

- **Manejo de Escalas y Tamaños:** Como el algoritmo usa una ventana de tamaño fijo ( $64 \times 128$ ), la solución para detectar una o más personas con distintos tamaños es escanear la imagen por secciones y luego reescalarla y repetir el escaneo.
- **Modelos Basados en Partes:** El cuerpo humano es altamente articulado y adopta posturas complejas. La evolución lógica es usar clasificadores que **detecten las partes del cuerpo de forma independiente** y analicen sus relaciones espaciales para inferir si conforman a una persona.
- **Formas No Humanas** Es posible adaptar los descriptores HoG para cualquier forma, y se deberá usar un clasificador especializado.

### ¿Qué se hace hoy en día? (La era del Deep Learning)

- **Representaciones Aprendidas:** Se pasó de diseñar descriptores a mano (*hand-crafted* como HOG) a usar Redes Neuronales que **aprenden las características** óptimas directamente de los datos.
- **Fin de la ventana deslizante:** Arquitecturas modernas analizan la imagen globalmente, resolviendo el problema de las escalas y posiciones en tiempo real sin escaneos exhaustivos.