

Bag of Visual Words

María Lourdes Vera Oliver, Solana Sabor Schwartz, Lara Grinspun,
Natalia Pérez y Belén Metzler

24 de junio de 2026


Reconocimiento de Objetos

- ¿A qué objeto pertenecen estas partes?



Algunas características locales
son muy informativas


Un objeto como



una colección de
características locales
(bolsa de características)

- maneja bien la oclusión
- invariante a la escala
- invariante a la rotación

Suposición (no tan) loca



La información espacial de las características locales se puede ignorar para el reconocimiento de objetos (es decir, verificación)

Conjunto de datos CalTech6

CalTech6 dataset



class	bag of features	bag of features	Parts-and-shape model
	Zhang et al. (2005)	Willamowski et al. (2004)	Fergus et al. (2003)
airplanes	98.8	97.1	90.2
cars (rear)	98.3	98.6	90.3
cars (side)	95.0	87.3	88.5
faces	100	99.3	96.4
motorbikes	98.5	98.0	92.5
spotted cats	97.0	—	90.0






Funciona bastante bien para la clasificación a nivel de imagen

Csurka et al. (2004), Willamowski et al. (2005), Grauman & Darrell (2005), Sivic et al. (2003, 2005)

Bolsa de características (Bag of features)



- Representar un elemento de datos (documento, textura, imagen) como un histograma sobre las características
- Una vieja idea(p. ej., reconocimiento de texturas y recuperación de información)

Reconocimiento de Texturas



Julesz, 1981. Mori, Belongie y Malik, 2001

Modelo de Espacio Vectorial



G. Salton. 'Mathematics and Information Retrieval' Journal of Documentation, 1979

Documento como un Vector

Un documento (punto de datos) es un vector de conteos sobre cada palabra (característica)

$$v_d = [n(w_{1,d}) \quad n(w_{2,d}) \quad \dots \quad n(w_{T,d})]$$

← simplemente un histograma sobre palabras

$n(\cdot)$ cuenta el número de ocurrencias

¿Cuál es la similitud entre dos documentos?



Documento como un Vector

Un documento (punto de datos) es un vector de conteos sobre cada palabra (característica)

$$v_d = [n(w_{1,d}) \quad n(w_{2,d}) \quad \dots \quad n(w_{T,d})]$$

$n(\cdot)$ cuenta el número de ocurrencias


← simplemente un histograma sobre palabras

¿Cuál es la similitud entre dos documentos?




Usa cualquier distancia que quieras, la distancia coseno es rápida.

$$\begin{aligned} d(v_i, v_j) &= \cos \theta \\ &= \frac{v_i \cdot v_j}{\|v_i\| \|v_j\|} \end{aligned}$$



Ponderación de Términos

- Pero no todas las palabras son creadas iguales



TF-IDF

Term **F**requency **I**nverse **D**ocument **F**requency
(Frecuencia de Término - Frecuencia Inversa de Documento)

$$v_d = [n(w_{1,d}) \quad n(w_{2,d}) \quad \dots \quad n(w_{T,d})]$$

Ponderar cada palabra mediante una heurística

$$v_d = [n(w_{1,d})\alpha_1 \quad n(w_{2,d})\alpha_2 \quad \dots \quad n(w_{T,d})\alpha_T]$$

$$n(w_{i,d})\alpha_i = \overset{\text{frecuencia de término}}{n(w_{i,d})} \overset{\text{frecuencia inversa de documento}}{\log \left\{ \frac{D}{\sum_{d'} \mathbf{1}[w_i \in d']} \right\}}$$

(reduce el peso de los términos comunes)


Pipeline estándar BOW

(para clasificación de imágenes)


"Vamos vamos Argentino"



"Vamos vamos Argentina"



1) Aprender dicionário visual




② nome $\rightarrow$ histograma (. - .)

③ Classificar, detectar, comparar

(1°)

CONSTRUCCIONES



 (~~x, d~~)

 (~~x, d~~)

 (~~x, d~~)

ANIMALES



 (~~x, d~~)

 (~~x, d~~)

 (~~x, d~~)


EXTRACCIÓN
DE
FEATURES

SIFT

(y otros)


$d(d(A)), d(I)$

$\text{dist}(d(A), d(B))$? $\text{dist}(d(A), d(B))$



KMEANS


$k=2$



die
wort

$$\left\{ \begin{array}{l} \star : (\dots \dots \dots) : \square \\ \star (\dots \dots \dots) \square \end{array} \right.$$



2°



2°



a) Extrusion
di
pezzi



2°



a) Extraction
de
features



(...)


b) quantization





(...)



(...)








2°



a) Extracción
de
Features




- ▣ (.....)
- ▣ (.....)
- ▣ (.....)




2°



a) Extracción de Features




b) Quantización



2°




a) Extracción de Features




b) Cuantización



cluster





Dictionary Learning (Aprendizaje de Diccionario):

Aprender Palabras Visuales usando agrupamiento (clustering)

Codificar:

construir vectores de Bolsas de Palabras (BOW) para cada imagen

Clasificar:

Entrenar y probar datos usando BOWs

Dictionary Learning

- 1. Extraer características (feature extraction) (p. ej., SIFT) de las imágenes




Dictionary Learning

- 2. Aprender diccionario visual (p. ej., agrupamiento K-means)




Codificar (Encode) - Paso 1



1. Cuantización: las características de la imagen se asocian a una palabra visual (centro del clúster más cercano)




2. Histograma: contar el número de ocurrencias de la palabra visual




¿Qué es la Extracción de Features?

- **El Problema:** Los píxeles crudos son inestables ante cambios de iluminación, perspectiva y ruido.
- **La Solución:** Traducir regiones de píxeles a vectores matemáticos compactos y distintivos.
- **Fases del proceso:**
 - **Localización:** ¿En qué coordenadas (x, y) de la imagen nos enfocamos?
 - **Descripción:** ¿Cómo resumimos matemáticamente la vecindad de ese punto?




Taxonomía del Muestreo: ¿De dónde extraemos?

- **Muestreo Denso (Regular Grid):** Cuadrícula uniforme. Ideal para capturar patrones globales y texturas continuas.
- **Puntos de Interés (Interest Point Detector):** Algoritmos que buscan singularidades geométricas (esquinas, gradientes fuertes). Invariantes a transformaciones.
- **Muestreo Aleatorio (Random Sampling):** Selección estocástica de parches. Eficiente estadísticamente en grandes volúmenes.
- **Basado en Segmentación:** Se agrupan píxeles homogéneos primero y luego se extraen features de esas regiones.



Repaso de SIFT

- **SIFT (Scale-Invariant Feature Transform):** Un detector de Puntos de Interés robusto.
- **Detección (El "Dónde"):**
 - Utiliza Diferencia de Gaussianas (DoG) sobre un espacio de escala.
 - Encuentra máximos/mínimos locales invariantes a la escala.
- **Descripción (El "Qué"):**
 - Calcula orientaciones de gradientes en una cuadrícula de 4×4 .
 - Resultado: Un vector en el espacio $\mathbb{R}^{128}$ robusto a rotación e iluminación.



¿Qué descriptores podemos usar?

El descriptor es “intercambiable”

El pipeline de Bag of Visual Words **no depende** de SIFT. Podemos usar cualquier descriptor que convierta un parche en un vector.

- **SIFT / SURF:** basados en gradientes y orientaciones. Robustos a escala y rotación. (*lo que vimos*)
- **HOG:** histograma de gradientes orientados. Muy usado en detección de personas.
- **ORB / BRIEF:** descriptores binarios, rápidos, pensados para tiempo real.
- **LBP (Local Binary Patterns):** basado en **textura**. Simple, rapidísimo y muy efectivo para caras y materiales. → **lo vemos ahora**.

¿Qué describe LBP?

La **textura local**: compara cada píxel con sus vecinos y resume el patrón en un número.

- Tomo un píxel central y sus **8 vecinos**.
- Cada vecino: si es $\geq$ que el central $\rightarrow 1$, si no $\rightarrow 0$.
- Leo los 8 bits en orden $\Rightarrow$ un número entre 0 y 255.

No importa el brillo absoluto, solo si el vecino es más claro o más oscuro
 $\Rightarrow$ **invariante a cambios de iluminación.**

Local Binary Patterns — El cálculo

6	5	2
7	6	1
9	8	7

1. Intensidades

umbral ≥ 6

1	0	0
1		0
1	1	1

2. Binarizo


3. Leo en orden

10001111₂
= **143**

Ese número (0–255) es el **código LBP** del píxel central. Lo calculo para **todos** los píxeles de la imagen / parche.

Local Binary Patterns — De códigos a descriptor

- Tras codificar todos los píxeles, hago el **histograma** de códigos LBP de la región.
- Ese histograma **es** el descriptor de textura del parche.
- **Versión uniform:** se observó que la mayoría de los patrones útiles tienen pocas transiciones $0 \rightarrow 1$ (bordes, esquinas). Agrupando los demás, bajamos de 256 a **59 bins**: más compacto y robusto.



Histograma LBP del parche

Conexión con Bag of Visual Words

LBP entra en el pipeline **en el mismo lugar que SIFT**: es otra forma de describir parches. Después, todo sigue igual: clustering $\rightarrow$ vocabulario $\rightarrow$ histograma de palabras $\rightarrow$ clasificación.

Antes de clasificar: ¿con qué datos entrenamos y evaluamos?

El problema de evaluar sobre lo que ya viste

- Si entrenamos y evaluamos el modelo con **las mismas imágenes**, no medimos si *aprendió* a reconocer la clase: medimos si **memorizó**.
- Queremos **generalización**: que funcione bien con imágenes **que nunca vio**.

Antes de clasificar: ¿con qué datos entrenamos y evaluamos?


El problema de evaluar sobre lo que ya viste

- Si entrenamos y evaluamos el modelo con **las mismas imágenes**, no medimos si *aprendió* a reconocer la clase: medimos si **memorizó**.
- Queremos **generalización**: que funcione bien con imágenes **que nunca vio**.

La solución: partir el dataset

- **Train (entrenamiento)**: se usa para construir el vocabulario (K-means) y entrenar el clasificador. Típicamente $\sim 70\text{--}80\%$.
- **Test (prueba)**: se aparta y **no se toca** hasta el final. Mide el rendimiento real. Típicamente $\sim 20\text{--}30\%$.

División del dataset



Regla de oro

El **vocabulario visual** también se aprende solo con **Train**. Si usás imágenes de Test para armar el codebook, ya estás “haciendo trampa”: filtrás información del Test al modelo (*data leakage*).


Algunas definiciones

- **Vocabulario visual = Libro de códigos (Codebook)**
- El libro de códigos se utiliza para cuantizar características.
- **Palabra visual = Vector de código (Code vector)**
- **Cuantización Vectorial:** Un cuantizador toma un vector de características (descriptor extraído de la imagen) y lo mapea al índice del vector de código (palabra visual) más cercano en el vocabulario.


¿A partir de qué datos debería aprender el Codebook?

- El vocabulario visual se puede aprender en un conjunto de entrenamiento separado.
- Si el conjunto de entrenamiento es lo suficientemente representativo, el diccionario será universal.
- El aprendizaje se realiza agrupando (*con clustering*) todos los descriptores extraídos (ej. todos los SIFT de todas las imágenes de entrenamiento) en K grupos.
- Las coordenadas de los K centroides resultantes conforman nuestro vocabulario de palabras visuales.


Construcción del Vocabulario Visual



Construcción del Vocabulario Visual



Construcción del Vocabulario Visual




Algoritmo K-means Clustering

Para agrupar los descriptores y encontrar las K palabras visuales, se utiliza comúnmente el algoritmo de K-means. Dado un número de clústeres K :


- 1 Seleccionar K centroides iniciales de forma aleatoria.
- 2 Asignar cada objeto (descriptor) al clúster con el centroide más cercano.
- 3 Recalcular cada centroide como la media de todos los objetos asignados a ese clúster.
- 4 Repetir los dos pasos anteriores hasta que no haya cambios en las asignaciones.

Algoritmo K-means Clustering




1. Select initial
centroids at random

Algoritmo K-means Clustering




1. Select initial centroids at random




2. Assign each object to the cluster with the nearest centroid.


Algoritmo K-means Clustering



1. Select initial centroids at random




2. Assign each object to the cluster with the nearest centroid.




3. Compute each centroid as the mean of the objects assigned to it (go to 2)


Algoritmo K-means Clustering




1. Select initial centroids at random



2. Assign each object to the cluster with the nearest centroid.



3. Compute each centroid as the mean of the objects assigned to it (go to 2)




2. Assign each object to the cluster with the nearest centroid.



Vocabulario Visual - Ejemplo



Vocabulario Visual - Ejemplo







description



$\longleftrightarrow N \longleftrightarrow$

10	30	11	12	13	29	22	12	13	30
10	10	12	34	12	10	12	34	12	9
12	29	11	10	12	10	12	34	12	14
3	10	12	34	12	10	12	34	12	14
12	12	3	10	12	12	3	10	12	
12	10	12	34	12	10	12	34	12	14
11	10	12	34	12	10	12	34	12	14
12	29	11	10	12	10	12	34	12	14
3	10	12	34	12	12	12	3	10	12
12	12	3	10	12	12	12	3	10	12
10	10	12	34	12	10	12	34	12	14
10	10	12	34	12	10	12	34	12	9
12	29	11	10	12	10	12	34	12	14
3	10	12	34	12	10	12	34	12	14
12	12	3	10	12	12	3	10	12	15
12	10	12	34	12	10	12	34	12	14
11	10	12	34	12	10	12	34	12	14
12	29	11	10	12	10	12	34	12	14
3	10	12	34	12	12	12	3	10	12
12	12	3	10	12	12	12	3	10	12
10	10	12	34	12	10	12	34	12	14
12	12	3	10	12	12	3	10	12	17


Vocabulario Visual - Ejemplo




Vocabulario Visual - Ejemplo

$\mathbb{R}^N$


Descripción de
todas las partes



Vocabulario Visual con K-means



Vocabulario Visual - K-means con K clusters



Coordenadas de los centroides





Diagram illustrating a data matrix with dimensions N (rows) and K (columns).


12	12	3	10	12	12	12	3	10	12
10	10	12	34	12	10	12	34	12	14
10	10	12	34	12	10	12	34	12	9
12	29	11	10	12	10	12	34	12	14
3	10	12	34	12	10	12	34	12	14
12	12	3	10	12	12	3	10	12	15

Vocabulario visual - Ejemplo



Vocabulario Visual - Ejemplo

Coordenadas de los centroides con $K=6$ clusters




N											
K	12	12	3	10	12	12	12	3	10	12	1
	10	10	12	34	12	10	12	34	12	14	2
	10	10	12	34	12	10	12	34	12	9	3
	12	29	11	10	12	10	12	34	12	14	4
	3	10	12	34	12	10	12	34	12	14	5
	12	12	3	10	12	12	3	10	12	15	6

Vocabulario visual - Ejemplo




Vocabulario visual - Ejemplo



Vocabulario visual - Ejemplo



10	11	11	32	11	13	12	31	13	15
----	----	----	----	----	----	----	----	----	----




Vocabulario visual - Ejemplo



10 11 11 32 11 13 12 31 13 15

12	12	3	10	12	12	12	3	10	12	1
10	10	12	34	12	10	12	34	12	14	2
10	10	12	34	12	10	12	34	12	9	3
12	29	11	10	12	10	12	34	12	14	4
3	10	12	34	12	10	12	34	12	14	5
12	12	3	10	12	12	3	10	12	15	6




Este vector es
representado
por la palabra 3


El Parámetro K (Tamaño del Diccionario)

- **Ventajas:** Funciona excelente para clasificación a nivel de imagen. Tolera oclusiones y transformaciones geométricas.
- **El problema del tamaño del vocabulario (K):**
 - **Si k es muy pequeño:** Las palabras visuales serán demasiado genéricas. Agruparás características visualmente distintas en el mismo centroide, perdiendo poder discriminativo (*underfitting*).
 - **Si k es muy grande:** Las palabras serán hiperespecíficas. Podríamos capturar ruido de las imágenes, aumentando el costo computacional sin mejorar la clasificación (*overfitting*).


Encode




Histograma



Histogram



Histograma



Histograma


TRAINING



Histograma

TRAINING

Para cada tigre del entrenamiento



Histograma


	X									y	
	5	4	1	2	3	4	...	6		1	
	6	3	2	3	4	3	...	5		1	
	5	2	2	4	3	2	...	4		1	
	4	1	4	3	2	1	...	4		2	
	3	2	3	2	1	2	...	3		2	
	2	3	2	1	2	3	...	2		2	
	1	4	1	2	3	4	...	1		3	
	2	5	2	3	4	5	...	2		3	
	3	6	3	4	5	6	...	3		3	
	4	5	4	5	6	5	...	4		4	
	5	6	5	6	5	6	...	5		4	
	6	7	6	5	6	7	...	6		4	
	5	8	5	6	7	8	...	5		5	
	6	9	6	7	8	9	...	6		5	
	7	0	7	8	9	0	...	7		5	

Normalización

¿Por qué normalizar?

Dos imágenes de la **misma clase** pueden generar muy distinta cantidad de keypoints (textura, tamaño). Sin normalizar, el clasificador separa por *cuántos* descriptores hay, no por *qué* palabras visuales aparecen.

Conteo crudo (img. con 600 keypoints)




Barras altas: solo refleja que la imagen tenía muchos keypoints.

$$\mathbf{L1} \quad \hat{h}_i = \frac{h_i}{\sum_j h_j}$$

lectura probabilística (suma 1)

Normalizado L1 (frecuencia relativa)



Misma *forma*, escala comparable entre imágenes ($\sum = 1$).

$$\mathbf{L2} \quad \hat{h}_i = \frac{h_i}{\|h\|_2}$$

preferida para SVM (norma 1)

¿Como comparamos dos histogramas?

- Distancia L1
- Distancia chi-cuadrado
- Distancia cuadrática (cross-bin)
- TF-IDF




Métodos discriminativos

- k-NN: a la imagen nueva le asigno la clase de la imagen de entrenamiento cuyo histograma sea más parecido, usando alguna de las distancias que mencionamos antes.
- SVM (Support Vector Machine): busca el hiperplano que separa las clases dejando el margen más grande posible entre ellas.


Métodos generativos

- Naive Bayes
- Modelos jerárquicos bayesianos: como pLSA o LDA



Spatial Pyramid representation






Spatial Pyramid representation



Spatial Pyramid representation



Spatial Pyramid representation



Referencias Principales

- Salton, G. (1979). *Mathematics and Information Retrieval*. Journal of Documentation.
- Lowe, D. (1999). *Object recognition from local scale-invariant features*. ICCV.
- Csurka, G. et al. (2004). *Visual categorization with bags of keypoints*. ECCV Workshop.
- Fei-Fei, L., & Perona, P. (2005). *A Bayesian Hierarchical Model for Learning Natural Scene Categories*. CVPR.
- Lazebnik, S., Schmid, C., & Ponce, J. (2006). *Beyond Bags of Features: Spatial Pyramid Matching for Recognizing Natural Scene Categories*. CVPR.
- Material integrado a partir de presentaciones de Kris Kitani (Carnegie Mellon University) y Domingo Mery (Universidad Católica de Chile).