

Segmentación de Regiones usando Graph Cuts

Gonzalez & Woods (4ta ed.) – Capítulo 10, Sección 10.6

Ignacio Maqueda

Solana Navarro

Bárbara Rivero

Lucio Tag

Elementos de Reconocimiento Visual

29 de junio de 2026

¿Qué significa segmentar una imagen?

¿Qué buscamos obtener?



Imagen original

Segmentación
→



Regiones obtenidas

Segmentar consiste en identificar las regiones principales de una imagen y separar objetos del fondo.

¿Qué esperamos de una buena segmentación?

Objetivo:

- ▶ Agrupar píxeles que pertenecen a una misma región.
- ▶ Separar regiones diferentes.
- ▶ Simplificar la interpretación de la escena.

Una segmentación útil debe producir regiones coherentes y significativas.


Limitación de los métodos clásicos

Métodos clásicos:

- ▶ Region Growing
- ▶ Split-and-Merge

Problema:

- ▶ Las decisiones se toman usando información local.
- ▶ Errores locales pueden afectar el resultado final.
- ▶ No consideran explícitamente la estructura global de la imagen.



Un único píxel anómalo puede inducir errores locales.

Idea

La similitud entre dos regiones puede depender de información distribuida en toda la imagen.

Cuando no sabemos qué hacer...

“Todo problema puede convertirse en un problema de grafos”

(al menos eso diría alguien que trabaja en Teoría de Grafos)

Idea

Los grafos permiten modelar relaciones entre elementos (en este caso, píxeles) y buscar soluciones globales mediante algoritmos eficientes.

Recordemos qué es un grafo


Un **grafo** se define como:

$$G = (V, E)$$

donde:

- ▶ V : conjunto de nodos (o vértices).
- ▶ $E \subseteq V \times V$: conjunto de aristas.

Las aristas representan relaciones entre pares de nodos.



En particular, los grafos utilizados en Graph Cuts son **no dirigidos** (la relación entre dos nodos es simétrica) y **ponderados** (las aristas poseen pesos que cuantifican la intensidad de la relación).

De una imagen a un grafo

- ▶ Cada píxel se representa mediante un nodo.
- ▶ La similitud entre píxeles se modela con pesos.
- ▶ Segmentar equivale a encontrar una partición óptima del grafo.


Idea central

La segmentación se transforma en un problema global de optimización.

Imagen como grafo


Representación de la imagen:

- ▶ Cada píxel se representa mediante un nodo.
- ▶ Se conectan píxeles vecinos mediante aristas.
- ▶ Los pesos representan similitud entre píxeles.



Interpretación de los pesos:

- ▶ Alta similitud $\Rightarrow$ peso alto.
- ▶ Baja similitud $\Rightarrow$ peso bajo.
- ▶ Los pesos bajos suelen indicar posibles fronteras entre regiones.




El concepto de corte

Versión simplificada:

- ▶ Conectividad 4-neighbors.
- ▶ Facilita la visualización.

Corte (Cut):

- ▶ Un corte divide el grafo en dos subconjuntos de nodos.
- ▶ Las aristas que conectan ambos subconjuntos son eliminadas.
- ▶ El objetivo es separar regiones diferentes de la imagen.



Idea clave

Segmentar una imagen equivale a encontrar un corte en el grafo.

¿Cómo medimos un corte?

Idea

Si eliminamos ciertas aristas para separar el grafo, el costo del corte será la suma de los pesos eliminados.

Definición: Dada una partición del conjunto de nodos en A y B :

$$A \cup B = V, A \cap B = \emptyset, \text{ definimos } \text{cut}(A, B) = \sum_{u \in A, v \in B} w(u, v)$$

Interpretación:

- ▶ Suma los pesos de las aristas que cruzan el corte.
- ▶ Un valor pequeño indica una conexión débil entre ambos grupos.


Objetivo

Encontrar una partición con valor de cut mínimo.

Relación con problemas de flujo

Teorema Max-Flow Min-Cut

En un grafo, el valor del flujo máximo entre una fuente y un sumidero es igual al costo del corte mínimo que los separa.



Este resultado permite calcular cortes mínimos mediante algoritmos de flujo máximo (por ejemplo, Ford-Fulkerson).


Incorporando Source y Sink

Agregamos dos nodos especiales:

- ▶ Source (S): representa el foreground.
- ▶ Sink (T): representa el background.

Conexiones terminales:

- ▶ Cada píxel p se conecta a S y a T .
- ▶ Los pesos $w(p, S)$ y $w(p, T)$ indican qué tan compatible es el píxel con cada clase.



Interpretación

Los nodos S y T actúan como prototipos de foreground y background.


Segmentación mediante un corte s-t

Corte s-t:

- ▶ El corte debe separar el nodo Source (S) del nodo Sink (T).
- ▶ Las aristas cortadas determinan la partición del grafo.

Resultado:

- ▶ Nodos del lado de $S \rightarrow$ foreground
- ▶ Nodos del lado de $T \rightarrow$ background



Idea clave

La segmentación se obtiene encontrando un corte que separe S y T con el menor costo posible.

¿Por qué no alcanza con Min-Cut?

Recordemos:

$$\text{mín cut}(A, B)$$

busca minimizar la suma de los pesos cortados.

Pensemos el siguiente ejemplo extremo:

Si p posee pocas conexiones, el siguiente corte puede resultar óptimo:

$$A = \{p\}, \quad B = V \setminus \{p\}$$

Problema:

- ▶ El criterio solo considera las conexiones entre grupos.
- ▶ No tiene en cuenta el tamaño de los grupos obtenidos.

Min-Cut puede favorecer particiones triviales o desbalanceadas.

Ejemplo de falla de Min-Cut

Observación:

- ▶ La región central constituye un grupo coherente.
- ▶ Sin embargo, el criterio Min-Cut prefiere aislar nodos periféricos.

Resultado:

- ▶ Se obtiene un corte barato.
- ▶ Pero la segmentación carece de significado.




Figura: Falla del Min-Cut

Problema

Un corte pequeño no implica una buena segmentación.

¿Qué falta en Min-Cut?

Una buena segmentación debe:

- ▶ Separar grupos diferentes.
- ▶ Mantener la coherencia interna de cada grupo.
- ▶ Evitar particiones muy desbalanceadas.

Idea

Necesitamos un criterio que combine separación + balance.

¿Cómo corregimos Min-Cut?

Min-Cut = costo del corte

Problema:

grupo pequeño $\Rightarrow$ costo pequeño

Idea:

$$\frac{\text{costo}}{\text{tamaño o conectividad del grupo}}$$

Midiendo la conectividad de un grupo

Idea:

Queremos cuantificar qué tan conectado está un conjunto de nodos con el resto del grafo.

Definición:

$$\text{assoc}(A, V) = \sum_{u \in A} \sum_{z \in V} w(u, z)$$

De forma análoga:

$$\text{assoc}(B, V) = \sum_{u \in B} \sum_{z \in V} w(u, z)$$

Interpretación

$\text{assoc}(A, V)$ mide la conexión total del conjunto A con todos los nodos del grafo.

Normalized Cut (Ncut)

Problema de Min-Cut:

- ▶ Favorece particiones pequeñas o desbalanceadas.

Idea:

- ▶ Normalizar el costo del corte usando la conectividad total de cada grupo.

Definición:

$$\text{Ncut}(A, B) = \frac{\text{cut}(A, B)}{\text{assoc}(A, V)} + \frac{\text{cut}(A, B)}{\text{assoc}(B, V)}$$

Interpretación

Un corte será favorable únicamente si:

- ▶ separa débilmente ambos grupos;
- ▶ y cada grupo mantiene una conectividad significativa.

Resumen del método Ncut

1. Construir el grafo correspondiente a la imagen.
2. Definir pesos de similitud.
3. Formular el criterio Ncut.
4. **Encontrar la partición que minimiza Ncut.**
5. Construir la segmentación final.

Pregunta

¿Cómo resolver eficientemente el paso 4?

¿Es fácil minimizar N_{cut} ?

$$\text{mín } N_{\text{cut}}(A, B)$$

- ▶ Cada partición posible del grafo produce un valor diferente de N_{cut} .
- ▶ El número de particiones crece exponencialmente con la cantidad de nodos.

Conclusión

Buscar la mejor partición por fuerza bruta resulta inviable para grafos grandes.

Representando el grafo mediante matrices

Hasta ahora describimos el grafo mediante:

- ▶ Nodos.
- ▶ Aristas.
- ▶ Pesos de similitud.

Para poder resolver el problema de manera eficiente, representaremos esta información utilizando matrices.

Idea

Las matrices permiten expresar el criterio Ncut y resolverlo mediante herramientas de Álgebra Lineal.

Matriz de similitud

Sea un grafo con n nodos.

La matriz de similitud se define como


$$W = (w_{ij})_{n \times n},$$

donde w_{ij} representa el peso de la arista entre los nodos i y j .

Interpretación

Cada entrada de W cuantifica la similitud entre un par de nodos del grafo.

Ejemplo: matriz de similitud



$$W = \begin{bmatrix} 0 & 5 & 7 & 0 \\ 5 & 0 & 0 & 8 \\ 7 & 0 & 0 & 9 \\ 0 & 8 & 9 & 0 \end{bmatrix}$$

Grafo ponderado

$$w_{ij} = \begin{cases} \text{peso entre } i \text{ y } j, & \text{si existe arista} \\ 0, & \text{en otro caso.} \end{cases}$$

Observación

Como el grafo es **no dirigido**, la matriz W es simétrica.

Matriz de grados

A partir de la matriz de similitud se define la **matriz de grados**

$$D = \text{diag}(d_1, d_2, \dots, d_n),$$

donde

$$d_i = \sum_{j=1}^n w_{ij}.$$

Interpretación

Cada elemento diagonal de D representa el grado ponderado de un nodo.

Ejemplo: matriz de grados

$$d_1 = 5 + 7 = 12$$

$$d_2 = 5 + 8 = 13$$

$$d_3 = 7 + 9 = 16$$

$$d_4 = 8 + 9 = 17$$

$$D = \begin{bmatrix} 12 & 0 & 0 & 0 \\ 0 & 13 & 0 & 0 \\ 0 & 0 & 16 & 0 \\ 0 & 0 & 0 & 17 \end{bmatrix}$$

Observación

La matriz D es diagonal: únicamente contiene los grados ponderados de cada nodo.

Matriz Laplaciana

A partir de las matrices W y D se define la **matriz Laplaciana**

$$L = D - W.$$

En el ejemplo anterior,

$$L = \begin{bmatrix} 12 & -5 & -7 & 0 \\ -5 & 13 & 0 & -8 \\ -7 & 0 & 16 & -9 \\ 0 & -8 & -9 & 17 \end{bmatrix}$$

Interpretación

La matriz Laplaciana resume simultáneamente la conectividad de cada nodo y las similitudes entre ellos.

De Ncut a un problema espectral

Mediante una relajación del problema de optimización, la minimización de Ncut conduce al problema de autovalores generalizado

$$(D - W)\mathbf{y} = \lambda D\mathbf{y}.$$

En lugar de explorar todas las particiones posibles, basta resolver este sistema matricial.

Resultado

La segmentación se obtiene a partir del autovector asociado al segundo menor autovalor.

¿Por qué el segundo autovector?

El problema espectral produce varios autovalores

$$0 = \lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_n.$$

Primer autovector

$$\mathbf{v}_1 = (1, 1, \dots, 1)^T$$

Todos los nodos reciben el mismo valor, por lo que no permite realizar ninguna partición.

Idea

El autovector asociado al segundo menor autovalor es el primero que contiene información sobre cómo separar el grafo en dos grupos.

Del autovector a la segmentación

Cada nodo recibe un valor dado por el segundo autovector.

Los nodos se dividen en dos grupos utilizando un umbral sobre dichos valores.

Idea

Nodos con valores similares en el segundo autovector tienden a pertenecer a la misma región.

Algoritmo completo de Normalized Cuts

1. Construir el grafo a partir de la imagen.
2. Definir los pesos de similitud.
3. Construir las matrices W y D .
4. Resolver el problema espectral.
5. Obtener el segundo autovector.
6. Particionar los nodos mediante un umbral.
7. Construir la segmentación final.

Ejemplo de segmentación mediante Normalized Cuts



Imagen original



Imagen suavizada



Segmentación

Observación

Antes de segmentar, la imagen puede suavizarse para reducir el efecto del ruido. Sobre esta imagen se construye el grafo y se aplica el criterio de Normalized Cuts.

Conclusiones

¿Qué aprendimos?

- ▶ Una imagen puede representarse mediante un **grafo ponderado**.
- ▶ La segmentación puede formularse como un problema de **partición del grafo**.
- ▶ El criterio **Min-Cut** puede producir particiones triviales.
- ▶ El criterio **Normalized Cut (Ncut)** incorpora el balance entre las regiones obtenidas.
- ▶ La minimización de Ncut conduce a un **problema espectral**, cuya solución aproxima la partición óptima del grafo.

Imagen $\longrightarrow$ Grafo $\longrightarrow$ Optimización $\longrightarrow$ Segmentación

Ventajas y limitaciones

Ventajas

- ▶ Utiliza información global de la imagen.
- ▶ Evita particiones triviales mediante Ncut.
- ▶ Produce regiones más coherentes.
- ▶ Posee una formulación matemática bien fundamentada.

Limitaciones

- ▶ Requiere resolver un problema espectral.
- ▶ El costo computacional puede ser elevado para imágenes grandes.
- ▶ El resultado depende de cómo se definan los pesos de similitud.

Conclusión

Graph Cuts constituye una de las técnicas más influyentes para segmentación de imágenes, al combinar herramientas de teoría de grafos, optimización y álgebra lineal.

Fin

¿Preguntas?